발전을 즐거워하는
김신웅입니다.

2026 Ericsson Korea
Portfolio

CAREER



개인정보

이름	김신웅
이메일	kshw19971029@gmail.com
전화 번호	010-5299-7402
소속 연구실	연세대학교 Smart System Lab (김우주 교수님)

학력

2013.03 ~2016.02	백석고등학교(경기)
2017.03 ~2023.02	숭실대학교 컴퓨터학부
2017.03 ~현재	연세대학교 디지털애널리틱스

경력

2017.01 ~2017.12	하남 구산주유소(정직원)
2019.09 ~2023.02	하남 구산주유소(정직원)
2023.03 ~2023.12	한화시스템 SW팀 Radar(연구원)

자격증

2023.09	데이터분석준전문가(ADsP)
2023.10	SQL개발자(SQLD)
2025.06	정보처리기사

기술 스택

PyTorch

주요 프로젝트

2024.09 ~2026.08	중소 패션기업을 위한 인공지능 기반 수요 예측 지원 시스템 개발	Multimodal, Time Series Forecasting
2025.04 ~2026.01	NexaBoard 제품 개발	LLM
2024.10 ~2025.12	인공지능 기반의 실시간 모델 관측가능성 및 설명가능성 제공을 통한 생애주기 관리 플랫폼 개발	XAI, LLM
2025.11 ~2026.02	스포츠 구장의 잔디 진단 AI 모형 개발	Computer Vision

기타 프로젝트

2021.03 ~2021.06	눈의 위치추적을 통한 부정행위 방지 시스템 (https://github.com/ALFEE19971029/SSUopenSource)	Computer Vision(Python), Web Backend(Java)
2023.01 ~2023.03	실종 동물찾기 위한 커뮤니티 제작 (https://github.com/ALFEE19971029/BanRyeohaeDyuoAWS)	Web Backend(Java)

논문

2025 CIKM Seoul workshop 발표 (2025.11.14, 2저자)	PPA-Net: Patch Pooling with Spectral Knowledge Distillation for Time Series Forecasting	Time Series Forecasting
지능정보연구 학술지 게재 (2025.12.31, 주저자)	생성형 언어 모델의 XAI 기법 비교 평가를 위한 지역적 충실도 기반 평가 프레임워크	XAI

PROJECT. 1

중소 패션기업을 위한 인공지능 기반 수요예측 지원 시스템 개발

프로젝트 정보 : 기업 용역 과제 / 참여인원 6명

목표 : 신상품 의류 상품이 향후 12주 동안 week 단위의 판매량 예측 모델 개발

프로젝트 설명 : 의류회사에서 연구실에 발주한 프로젝트입니다. 보통의 Time Series Forecasting task와 다르게 과거 판매 시계열 데이터가 없는 '신상품' 의류에 대해 판매 예측을 수행하는 Zero Shot Forecasting task입니다. 2013년 1월부터 2024년 9월까지 약 3만개의 아이템에 대한 판매데이터를 기업에서 제공하였고 이 중 2024년 9월 기준으로 가장 최근에 팔린 아이템 2484개를 Test로 사용하였습니다. Test에 대한 성능 평가는 제품의 출시 week 이후 12주간의 판매량으로 진행을 기업으로부터 요청받았습니다.

데이터 :

- 의류 하나 당 :
  - 품번 : JPKT727FPK (약 3만개)
  - 출시일 : 2015-10-19 (2013년 1월 ~ 2024년 9월)
  - 12주 판매량 : 11, 9, 5, 9, 10, 1, 8, 5, 0, 0, 0, 4
  - 색깔 : orange, pink, blue, white, black, mint, green, beige, red, yellow, khaki, grey, purple, brown, gold,
  - 섬유(fabric) : denim, jersey, woven 등
  - 카테고리 : PD(패딩), SW(스웨터) 등
  - 이미지
  - 상품 설명 : 스트레치성이 있는 탄탄한 코튼소재로 매끈하고 깔끔한 외관의 치노팬츠 입니다.



평가지표 : RMSE, MAE

수행업무 :

1. GTM Transformer[1] Encoder 외생변수 변경
   → 소비자물가지수, Naver 검색량 등
2. 제품의 Image와 Text를 FashionCLIP으로 임베딩
3. 선행연구 조사 및 적용
4. 발주회사 사용 API 서비스 구축
5. 발주회사 담당자분들과 소통하며 프로젝트 리딩

Key Contribution 1 (Fourier Mapping) :

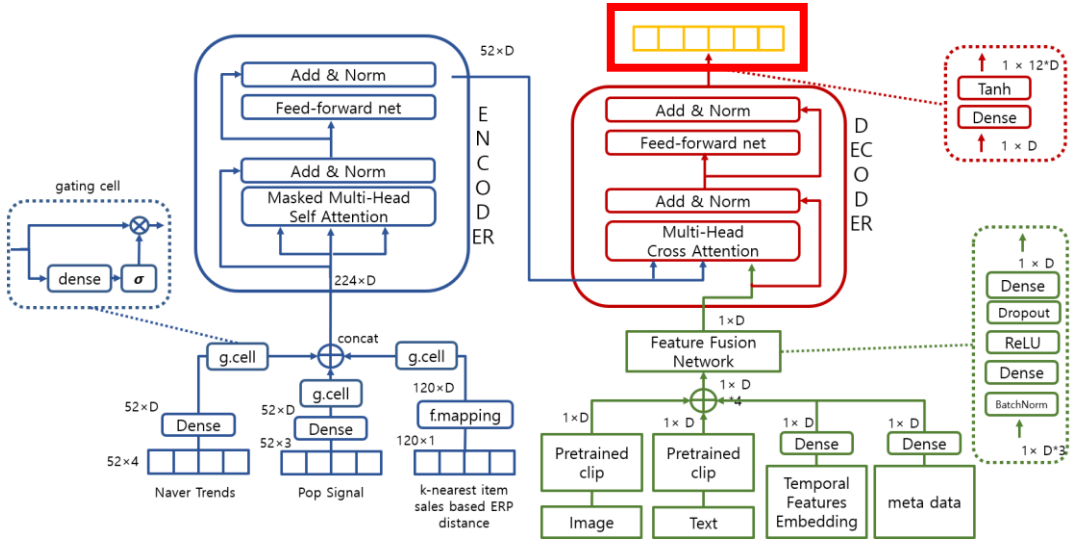
- 기존 모델은 normalization 과정에서 판매 패턴 손실 발생
- 제품별로 판매량 Scale의 편차가 크기 때문에 Scale 예측이 어려움
- 이를 해결하기 위해 Fourier feature 기반 접근[2]에서 아이디어 차용
- 판매량을 직접 예측하는 것이 아닌 Fourier 값을 예측하도록 구조 변경
- 방법론 요약 (예시) :

1. Target label : 12주 판매량 [9,11,13,14,18,17,15,19,23,22,20,24]
2. 1주차 판매량 9개에 대해 Fourier mapping 진행 (Transformer Positional Encoing 과정과 동일)

$$9 \rightarrow [\sin(f1 \cdot 9), \cos(f1 \cdot 9), sin(f2 \cdot 9), \cdots] \in R^{500}$$

3. 최종 fourier mapping 결과($R^{500\times12}$)를 모델이 예측하도록 설계

- 결과 : MAE 24.87 → 24.4



[1] Well googled is half done: Multimodal forecasting of new fashion product sales with image-based google trends. Journal of Forecasting (2024)
[2] Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains (NIPS 2020)

PROJECT. 1

중소 패션기업을 위한 인공지능 기반 수요예측 지원 시스템 개발

Key Contribution 2 (ERP-based Similarity Learning) :

- cold-start 환경에서 유사 상품 기반 reference 활용
- 유사 상품 패턴을 잘 활용하기 위한 방법 고안
- 방법론 요약 :

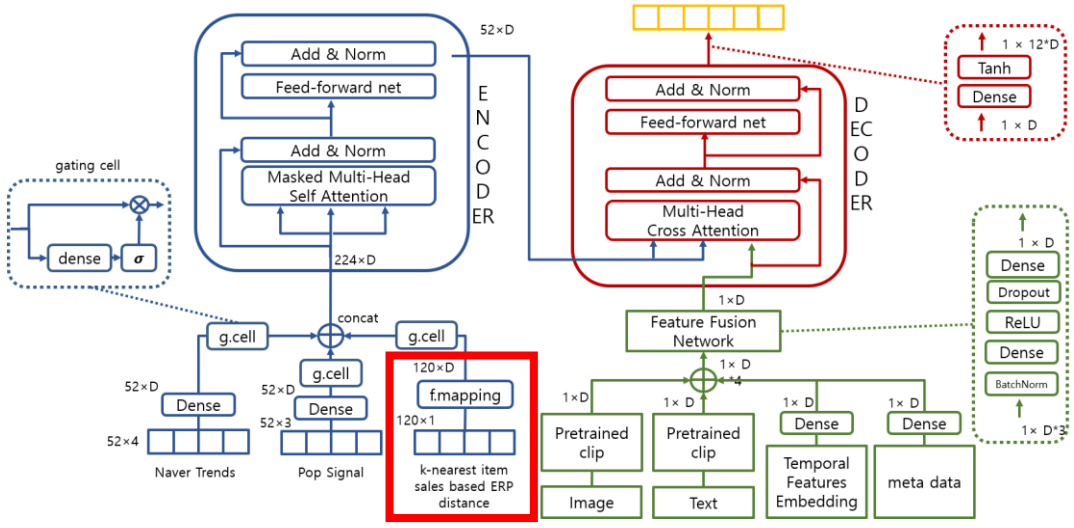
Training Stage

1. Train 상품들의 12주 판매데이터에 대해서 상품간의 ERP distance 계산
2. 1개의 아이템에 대해서 ERP distance가 가까운 상위 10개 아이템 선정
3. 상위 10개 아이템은 positive pair, 그 외의 아이템은 negative pair로 구성
4. 상품 메타데이터의 임베딩 값을 encoding(MLP)하여 Contrastive Learning 진행

Inference Stage

1. 예측 대상 상품을 동일 encoder로 embedding 생성
2. embedding 공간에서 가장 유사한 reference 상품 10개 retrieval
3. retrieved 상품들의 판매 패턴을 GTM Encoder에 context로 활용

- 결과 : MAE 24.4 → 24.1

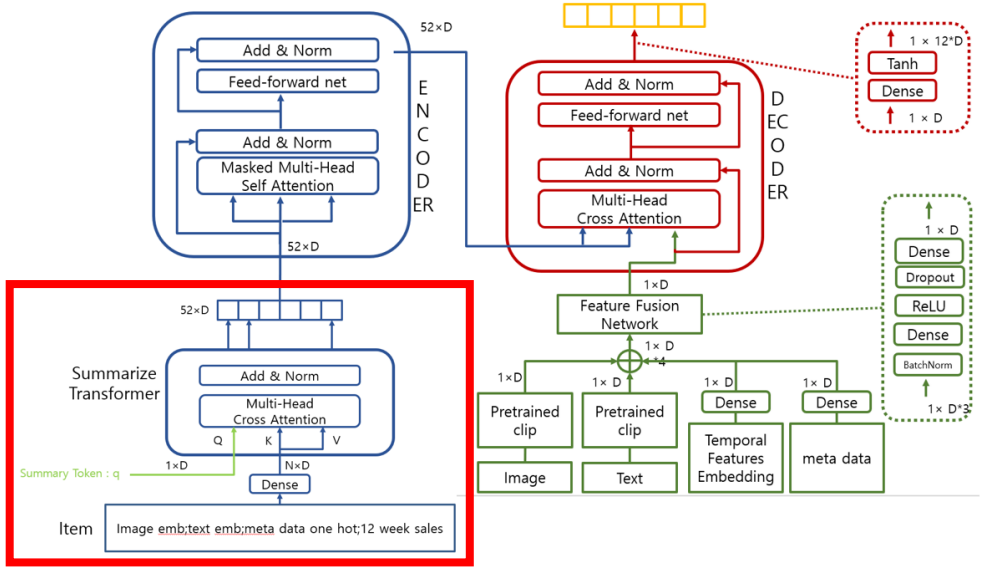


Key Contribution 3 (Summarizing Past Context) :

- 기존의 의류 수요 예측 모델은 다른 상품과의 상호작용을 고려하지 않음
- 과거의 판매 Context가 현재 예측하려는 상품에 영향을 줄 것이라는 가설 수립
- 과거 판매 데이터를 적절하게 요약하여 GTM Transformer Encoder에 input
- Set Transformer의 PMA 모듈[1]에서 아이디어 차용
- 방법론 요약 :

1. Train 상품을 멀티모달 임베딩으로 토큰화 : $z_{w,j} \in R^K$, where w : week, j : item
2. 주별 토큰 행렬 생성 : $Z_w = [z_{w,1}; z_{w,2}; \ldots; z_{w,N}] \in R^{N \times K}$ where N : 아이템 수
3. Learnable Summary Token 정의 (D차원 파라미터) : $q \in R^D$
4. Multi-head Attention 요약 : $Q = qW_Q$, $K_w = Z_w W_K$, $V_w = Z_w W_V$
5. 주별 요약 벡터 생성 후 Encoder에 입력

- 결과 : MAE 24.87 → 24.35



[1] Set Transformer: A Framework for Attention-based Permutation-Invariant Neural Networks (ICML 2019)

PROJECT. 2

NexaBoard 제품 개발

프로젝트 정보 : 기업 용역 과제 / 참여인원 11명

목표 : 사용자의 발화로부터 사용자의 의도를 파악해서 데이터베이스 SQL 결과를 시각화하여 웹페이지에 출력

프로젝트 설명 : 상용 소프트웨어 회사가 발주한 프로젝트입니다. NexaBoard라는 제품으로 출시 예정입니다. Task를 3개로 나누어서 진행하였습니다.
(Task 1) NexaBoard의 사용자가 발화를 하면 STT 모듈이 이를 텍스트로 변환해줍니다.
Ex. 상담원별 평균 문의 응답 시간을 어두운 테마에서 범례를 오른쪽에 두고 도넛 차트로 시각화해줘
(Task 2) Task1에서 받은 텍스트에서 사용자의 의도를 json 포맷으로 추출합니다.
Ex. {"Chart type" : "doughnutChart", "Theme type" : "dark", "legend" : "rightcenter"}
(Task 3) Task1에서 받은 텍스트의 의도에 맞게 SQL로 변경하여 DB에서 결과를 가져옵니다.
Ex.

```
SELECT
  c.consultantName,
  AVG(r.responseTime) AS avg_response_time
FROM
  consultant c
  JOIN request r ON c.consultantId = r.consultantId
GROUP BY
  c.consultantName
ORDER BY
  avg_response_time;
```

최종 결과는 발주 회사 서버에 JSON payload를 POST하여 회사 웹페이지에 출력하였습니다.

데이터 : 사용자 발화 데이터 2049개 Label은 Task2에 대해서만 제공

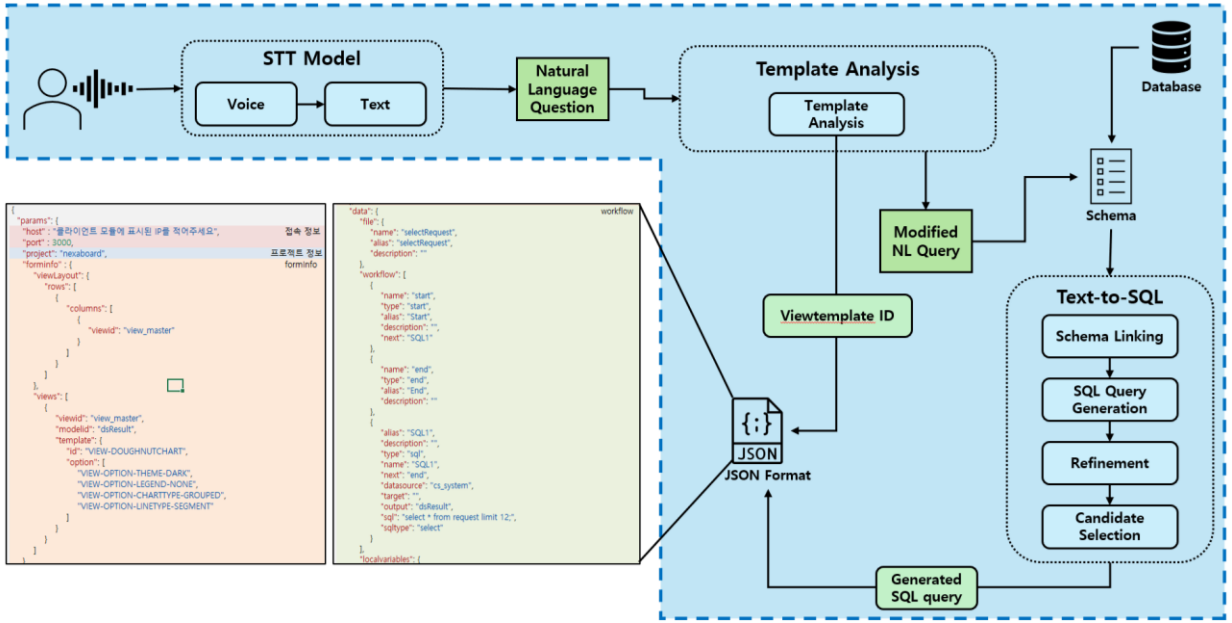
Query	Expression	OptionValues
상담원별 평균 문의 응답 시간을 묶음 형태로 밝은 테마에서 범례를 하단에 두고 바 차트로 시각화해줘	바 차트로	grouped, light, bottomcenter
고객 성별별 요청 수를 누적 형태로 푸른 테마로 범례 없이 column 형식으로 시각화해줘	column 형식으로	stacked, blue, none
상담원별 평균 문의 응답 시간을 붉은 테마에서 범례를 상단에 두고 복합 차트로 시각화해줘	복합 차트로	red, topcenter
상담원별 평균 문의 응답 시간을 초록 테마에서 범례를 상단에 두고 파이 차트로 시각화해줘	파이 차트로	circle, green, topcenter

평가지표 : (Task1,3) 정성적 평가 (Task2) Accuracy, F1 Score

수행업무 :
1. Task 2 LangGraph로 구현, LLM Prompting
2. Task 3 XiyanSQL 모델 구현, LangGraph pipeline 구축
3. NexaBoard 시연용 Socket 프로그램 구축

Key Contribution 1 (ToolLearning) :

- LLM의 출력이 자유생성 방식으로 JSON으로 파싱하는 과정에서 형식화된 출력이 나오지 않는 문제 발견
- LLM의 형식화된 출력을 위해 ToolLearning의 함수와 인자를 사용하여 사용자의 의도를 형식화된 출력으로 파싱하도록 변경
- ChatGPT를 활용한 증강 데이터와 LoRA 파인튜닝을 통해 의도 분류 Accuray 0.51 → 0.7로 개선



Overall Architecture

PROJECT. 3

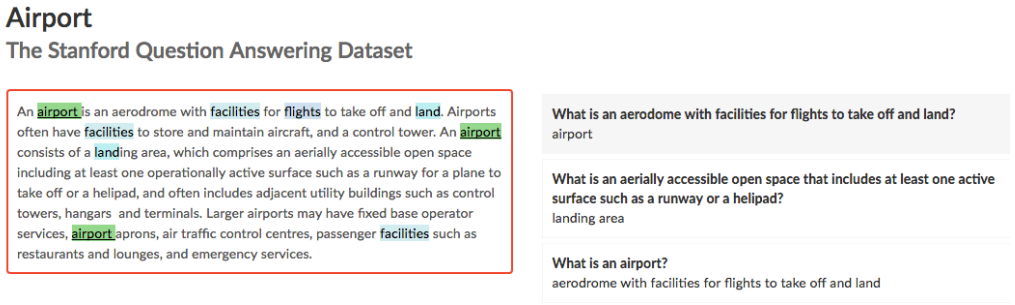
인공지능 기반의 실시간 모델 관측가능성 및 설명가능성 제공을 통한 생애주기 관리 플랫폼 개발

프로젝트 정보 : 산학 과제 / 참여인원 5명

목표 : QA태스크에 대해서 LLM 출력에 영향을 주는 토큰 중요도 판별

프로젝트 설명 : XAI 프로젝트로 LLM이 생성한 응답에 대해 어떤 입력 토큰이 결과에 핵심적으로 기여했는지를 정량적으로 분석하고 토큰 단위 중요도를 제공하는 방법론을 개발하는 것을 목표로 수행되었습니다. 기존 설명기법인 SHAP을 baseline으로 설정하고 QA 태스크 환경(SQuAD 데이터셋, DROP 데이터셋)을 기준으로 설명 품질을 비교 평가하였습니다.

데이터 : SQuAD 데이터 1000개, DROP 데이터 1000개



평가지표 : AUPC, ELFM(자체제작)

수행업무 :
1. 다양한 LLM XAI 방법론 구현 및 적용
2. 기업 제공용 API 서비스 구축

Key Contribution 1 (Learnable Masking) :

- LLM의 입력 토큰을 단순히 삭제 시 출력의 무의미하게 바뀌는 문제 발생
- 토큰을 삭제하기보다 벡터 단위에서 확률적으로 masking할 수 있는 방법 필요
- Computer Vision에서 pixel 중요도를 설명하는 [1]에서 아이디어 차용
- [1]에서의 Preservation 경우와 Deletion 경우 모두를 동시에 적용할 수 있는 방법 고안
- 방법론 요약 :

1. Original Input X에 대한 LLM 출력 Y 계산
2. 토큰 별 Attribution Map(중요도 맵) $\in w^k$, k : 토큰의 개수
3. 마스킹 수행 과정 : $M(a,X) = \{a[i] \cdot X_k + (1-a[i]) \cdot e\}\ for\ all\ k$

$where,\ M$: 마스킹 결과, X : input vector, X_k : k번째 토큰 vector, a : attribution map
e : 방해요소 (문맥 보존을 위해서 임베딩 mean을 사용)

4. 마스킹 수행 과정을 Preservation 경우와 Deletion 경우 모두 수행

Preservation Game Masking : $X' = M(a,X)$
Deletion Game Masking : $X'' = M(1-a,X)$

4. Loss Function 설계 후 학습

Loss Function : $L_{total} = \lambda_1 L_1\big(F(X),F(X')\big) + \lambda_2 L_2\big(F(X),F(X')\big) + \lambda_3 L_3(a)$

$where,\ \lambda$: 하이퍼파라미터, L_1, L_2 : BertScore 유사도, L_3 : attribution map 정규화 항

- 결과 : SQuAD 기준 SHAP AUPC 0.59 → Learnable Masking AUPC 0.68



Key Contribution 2 (ELFM 평가 프레임워크 제안) :

- LLM XAI 기법 별 평가 metric이 달랐기 때문에 방법론 간의 비교의 어려움
- LLM XAI 기법들 간 비교가 가능한 평가지표 설계 고안
- 논문 link : https://www.kci.go.kr/kciportal/ci/sereArticleSearch/ciSereArtiView.kci?sereArticleSearchBean.artiId=ART003286183

[1] Interpretable Explanations of Black Boxes by Meaningful Perturbation (ICCV 2017)

PROJECT. 4

스포츠 구장의 잔디 진단 AI 모형 개발

프로젝트 정보 : 기업 용역 과제 / 참여인원 3명

목표 : 잔디 이미지에 대한 잔디 상태 image classification

프로젝트 설명 : 축구장 관리를 위해 잔디 사진이 주어졌을 때, 잔디의 상태를 분류하는 과제입니다.

데이터 :
- 기업 데이터 제공 X → AI hub 잔디생육환경 오픈 데이터
- Image 라벨 : 건강한잔디, 물리적손상잔디, 잡초, 병해잔디, 충해잔디 (5 classes)
- image segmentation 목적 데이터셋으로 라벨 polygonal 좌표값도 존재



물리적손상잔디

	건강한 잔디	병해 잔디	물리적 손상 잔디	충해 잔디	잡초
Train	12,351	4,540	4,021	4,008	3,938
Valid	1,372	504	446	445	437
Test	1,706	646	560	555	534

평가지표 : Accuracy, F1 Score

수행업무 :
1. 다양한 image classification 모델 적용
2. 하이퍼파라미터 변경

Key Contribution (이진 분류 모델로 분할) :

- AI hub 데이터셋의 문제 : 잔디 사진에 물리적손상잔디, 잡초 등 여러가지 클래스에 대한 feature가 이미지에 존재하지만 라벨링은 only one class로 구성
- Image classification 모델 하나로 multi class 분류로 진행할 경우, noise들이 많아서 학습이 불안정
- 라벨링이 부족하지만 존재하는 라벨은 무조건 정답 → 이진분류로 분리해서 접근
- 5가지 클래스를 이진분류 모델 5개로 각각 예측
- 결과 : 기존 ConvNeXt accuracy 0.70 → 이진 분류 모델 accuracy 0.82

클래스	accuracy
물리적손상 잔디	0.5874
건강한잔디	0.7869
잡초	0.5900
충해잔디	0.5889
병해잔디	0.9726

ConvNeXt

➡

클래스	accuracy
물리적손상 잔디	0.7568
건강한잔디	0.8171
잡초	0.9457
충해잔디	0.7393
병해잔디	0.8467

이진분류 ConvNeXt × 5

감사합니다.